GUÍA DE PALABRAS CLAVE

Qué tienes que explicar, qué significa cada término y para qué sirve todo

Tesis: **Comparación de algoritmos de regresión de aprendizaje supervisado para la predicción de la precipitación mensual en el Perú**

Autor: Atahualpa Palomino, Kevin Anthony · Asesor: Mg. Flores Chacon, Erick Giovanny
Universidad César Vallejo · Sede Lima Este · Línea: Sistemas de Información y Comunicaciones · Año académico 2026

1 · La tesis en 30 segundos

Se compararon **cuatro algoritmos de regresión de aprendizaje supervisado** (Regresión Ridge, Regresión KNN, Random Forest y XGBoost) para predecir la **precipitación mensual** en cada celda del territorio peruano, usando el dataset **PISCOp v3.0** del SENAMHI (540 meses: 1981-2025). Todos los modelos superaron los criterios de aceptación y el ganador fue **Regresión Ridge** (RMSE 74,23 mm · R^2 0,80), elegido por tener el menor RMSE y el mayor R^2. El resultado se entrega en un prototipo web con forma de sistema operativo científico: **Precipitación Perú OS**.

2 · El flujo del trabajo en 5 pasos

PASO	QUÉ SE HIZO	CIFRA CLAVE
1 · Recolección	Dataset PISCOp v3.0 (SENAMHI): 540 meses × 210 × 174 celdas de 0,1°.	19 731 600 celda-mes
2 · Limpieza (ETL)	Eliminación de centinelas (valores sin dato).	15 782 040 válidos (79,98 %)
3 · Variables	D1 = objetivo · D2 = estadísticos climatológicos · D3 = rezagos.	k = 1, 2, 3, 12
4 · Partición	Entrenamiento y prueba separados y fijos para los 4 modelos.	11 573 496 train · 3 857 832 test
5 · Modelos	Regresión Ridge · Regresión KNN · Random Forest · XGBoost (semilla 42).	4 algoritmos
6 · Evaluación	MAE, RMSE, R^2 y métricas relativas frente a la línea base de persistencia.	3 de 3 umbrales cumplidos
7 · Aplicación	Proyección 2026 y análisis regional de los 25 departamentos.	media anual 184,54 mm/mes

3 · Palabras clave que debes poder explicar

Fundamentos de aprendizaje supervisado

Aprendizaje supervisado: El modelo aprende de ejemplos ya resueltos: se le dan las entradas y la respuesta correcta (la lluvia real) y él encuentra el patrón para predecir casos nuevos.

Regresión: Tipo de problema donde lo que se predice es un número continuo (milímetros de lluvia), no una categoría. Por eso se usan algoritmos de regresión y no de clasificación.

Variable objetivo (D1): Lo que queremos predecir: P(c,t), la precipitación de la celda c en el mes t.

Características o entradas (features): Los datos con los que el modelo adivina: estadísticos climatológicos (D2) y rezagos (D3).

Conjunto de entrenamiento y de prueba: El entrenamiento (11 573 496 registros) sirve para aprender; el de prueba (3 857 832 registros) se guarda aparte para medir si el modelo acierta en datos que nunca vio. Si se mezclan, la evaluación es falsa.

Semilla 42: Valor fijo que hace reproducible todo lo aleatorio del experimento (submuestras, bosques). Con la misma semilla, cualquiera obtiene los mismos números.

Sobreajuste (overfitting): Cuando el modelo memoriza el entrenamiento y falla en datos nuevos. Su opuesto, el subajuste, es quedarse corto y no capturar el patrón. La regularización existe para evitar el sobreajuste.

Hiperparámetro: Configuración que se elige antes de entrenar (por ejemplo la k del KNN). No se aprende de los datos: se decide en el experimento.

Los datos

PISCOp v3.0 (SENAMHI): Producto de precipitación del Servicio Nacional de Meteorología e Hidrología del Perú que combina observaciones de estaciones con datos satelitales. Cubre 1981-2025.

Malla o grilla de 0,1°: El país dividido en 210 × 174 celdas cuadradas de 0,1° (unos 10 km de lado). Cada celda tiene su propia serie de lluvia mensual.

Celda-mes: Una celda en un mes concreto: la unidad básica del dataset. En total 19 731 600; tras la limpieza quedan 15 782 040 válidos (79,98 %).

Centinela: Valor de relleno que significa "aquí no hay dato". No es un cero de lluvia: se elimina en el preprocesamiento para no ensuciar el aprendizaje.

D2 · estadísticos climatológicos: Para cada celda y cada mes del calendario: la media histórica μ(c,m), la desviación estándar σ(c,m) con corrección N–1 y la media total P■(c). Le dan al modelo el "clima normal" de cada lugar.

D3 · rezagos (lags): La lluvia de meses anteriores como entrada: k = 1, 2, 3 y 12 (el mes pasado, hace dos, hace tres y hace un año). La precipitación tiene memoria y estacionalidad.

Rango de los datos: Precipitación mensual de 0,00 a 6 153,58 mm. Los valores extremos son justo lo que más cuesta predecir.

Los cuatro algoritmos

ALGORITMO	QUÉ ES EN UNA FRASE	DATO DEL EXPERIMENTO
Regresión Ridge GANADOR	Regresión lineal con regularización L2: castiga los coeficientes muy grandes para que el modelo no se sobreajuste. Simple, rápido y estable aunque las variables estén correlacionadas.	MAE 48,29 · RMSE 74,23 · R^2 0,80 · 1 500 000 obs.
Regresión KNN	K vecinos más cercanos: para predecir busca los k registros parecidos al caso nuevo y promedia sus lluvias reales (k = 7). No asume ninguna forma matemática, pero es costoso con millones de datos.	MAE 51,81 · RMSE 79,95 · R^2 0,77 · 300 000 obs.
Random Forest	Bosque aleatorio: muchos árboles de decisión entrenados con muestras diferentes; la predicción es el promedio de todos. Robusto ante ruido y relaciones no lineales.	MAE 48,87 · RMSE 75,82 · R^2 0,79 · 300 000 obs.
XGBoost	Impulso de gradiente (gradient boosting): árboles que se entrenan en secuencia, cada uno corrigiendo los errores del anterior. Muy potente con datos tabulares.	MAE 48,26 · RMSE 75,17 · R^2 0,79 · 300 000 obs.

Submuestra técnica: por el costo computacional de trabajar sobre millones de observaciones, Regresión KNN, Random Forest y XGBoost se entrenaron con 300 000 observaciones extraídas aleatoriamente del conjunto de entrenamiento con semilla fija (42); esta limitación se documenta en la interpretación de los resultados. Regresión Ridge, al ser lineal, procesó 1 500 000 observaciones.

Las métricas (cómo se mide el desempeño)

MAE · error absoluto medio: En promedio, cuántos milímetros se equivoca el modelo. Fácil de explicar: "se equivoca como media unos 48 mm".

RMSE · raíz del error cuadrático medio: Parecido al MAE pero castiga mucho más los errores grandes. Es la métrica clave cuando los extremos importan (inundaciones, sequías).

R^2 · coeficiente de determinación: Qué proporción de la variabilidad de la lluvia explica el modelo (1,00 = perfecto; 0,80 = explica el 80 %).

Métricas relativas (rel. MAE y rel. RMSE): El error del modelo dividido por el de la línea base de persistencia. El ganador obtuvo 0,47 y 0,49, es decir, reduce el error un 53 % (MAE) y un 51 % (RMSE) frente a esa base.

Línea base de persistencia: La predicción más simple posible: asumir que el mes siguiente lloverá como el mes pasado. También se comparó con la climatología (predecir siempre el valor medio de cada celda). Todo modelo debe superar a estas bases para tener valor práctico.

Criterios de aceptación: Los tres umbrales definidos en la metodología: rel. MAE menor que 0,90 · rel. RMSE menor que 0,90 · R^2 mayor o igual que 0,75 (nivel excelente). Los cuatro algoritmos cumplieron 3 de 3.

4 · Los resultados y cómo explicarlos

MODELO	OBS. ENTREN.	MAE (mm)	RMSE (mm)	R^2	REL. MAE	REL. RMSE	ESTADO
Regresión Ridge	1 500 000	48,29	**74,23**	**0,80**	0,47	0,49	GANADOR
XGBoost	300 000	**48,26**	75,17	0,79	0,47	0,50	CUMPLE
Random Forest	300 000	48,87	75,82	0,79	0,48	0,50	CUMPLE
Regresión KNN	300 000	51,81	79,95	0,77	0,51	0,53	CUMPLE

Métricas del modelo ganador verificadas: MAE 48,29 · RMSE 74,23 · R^2 0,80 · rel. MAE 0,47 · rel. RMSE 0,49.

Cómo defender la elección de Regresión Ridge

- El criterio de selección fue **menor RMSE y mayor R^2**: Ridge tiene el RMSE más bajo (74,23 frente a 75,17 de XGBoost) y el R^2 más alto (0,80 frente a 0,79).
- XGBoost sí tiene el MAE más bajo (48,26), pero solo por **0,03 mm** sobre Ridge (48,29): una diferencia prácticamente nula, dentro del ruido del experimento.
- El RMSE penaliza los errores grandes, y en precipitación los errores grandes son los meses extremos: por eso pesa más que el MAE en la decisión.
- Ridge además es más simple, más rápido de entrenar y de interpretar, y trabajó con más datos (1 500 000 observaciones). Entre dos modelos casi iguales, se elige el más simple: menos riesgo de sobreajuste.
- Los cuatro modelos cumplieron los 3 criterios de aceptación: la comparación no busca "malos y buenos", sino el mejor equilibrio.

5 · La utilidad: para qué sirve todo esto

Gestión del agua: Estimar con antelación la lluvia de cada mes ayuda a planificar reservas para consumo urbano, riego y generación hidroeléctrica.

Agricultura: Permite decidir cuándo sembrar y cosechar según la lluvia esperada en cada región, reduciendo pérdidas por sequías o excesos de agua.

Riesgo hidrológico: Anticipar meses muy lluviosos o muy secos apoya la prevención de inundaciones, deslizamientos y sequías, y el seguimiento de fenómenos como El Niño.

Planeamiento regional: El ranking departamental permite priorizar recursos: Loreto 244,96 · Madre de Dios 214,66 · Pasco 209,16 · Ucayali 191,37 · Amazonas 186,45 mm/mes.

Proyección operativa: La proyección 2026 entrega los 12 meses del año (media anual 184,54 mm/mes), generada de forma recursiva con el modelo ganador y recortada a valores no negativos.

Ciencia reproducible: Datos oficiales del SENAMHI, semilla fija, metodología documentada y prototipo publicado: cualquiera puede verificar y repetir el experimento.

6 · Qué explicar en la exposición (guion de 5 minutos)

- **1 · El problema (30 s):** predecir la lluvia mensual en el Perú importa para el agua, la agricultura y la prevención de desastres.
- **2 · Los datos (45 s):** PISCOp v3.0 del SENAMHI, 540 meses (1981-2025), malla de 0,1°, 15 782 040 registros válidos (79,98 %).
- **3 · La comparación (60 s):** cuatro algoritmos de regresión supervisada, las mismas particiones de entrenamiento y prueba, semilla 42.
- **4 · Los resultados (90 s):** los cuatro cumplen los criterios; gana Regresión Ridge por el menor RMSE (74,23) y el mayor R^2 (0,80).
- **5 · La aplicación (60 s):** proyección 2026, análisis de los 25 departamentos y el prototipo Precipitación Perú OS publicado en la web.
- **6 · Cierre (15 s):** el trabajo es reproducible y está disponible en internet para consulta.

7 · Preguntas probables del jurado (y cómo responderlas)

¿Por qué gana Ridge si XGBoost tiene el MAE más bajo?

Porque la selección se definió por menor RMSE y mayor R^2. XGBoost solo gana el MAE por 0,03 mm (48,26 frente a 48,29), una diferencia despreciable, mientras que Ridge tiene mejor RMSE (74,23 frente a 75,17) y mejor R^2 (0,80 frente a 0,79).

¿Qué es la regularización L2 (la base de Ridge)?

Un castigo matemático a los coeficientes muy grandes del modelo lineal. Evita que el modelo se ajuste en exceso al ruido de los datos de entrenamiento (sobreajuste).

¿Por qué KNN con k = 7?

El valor de k se fijó durante la fase de validación del experimento. La k define cuántos vecinos se promedian: k pequeña se ajusta mucho al ruido, k grande pierde detalle local.

¿Por qué algunos algoritmos usaron 300 000 registros y Ridge 1 500 000?

Por costo computacional: buscar vecinos o entrenar ensambles sobre los 11 573 496 registros de entrenamiento es muy demandante, por eso se usó una submuestra técnica de 300 000 observaciones con semilla fija, igual para los tres. Es una limitación documentada en la interpretación de resultados.

¿Qué significa el R^2 de 0,80?

Que el modelo explica el 80 % de la variabilidad de la precipitación mensual en los datos de prueba que nunca había visto.

¿Para qué sirven los rezagos?

La lluvia de un mes se parece a la de los meses anteriores. Los rezagos k = 1, 2, 3 y 12 aportan esa memoria (incluido el ciclo anual) como entradas del modelo.

¿Qué es la línea base de persistencia?

Predecir asumiendo que lloverá como el mes anterior. Es la referencia mínima: nuestro modelo logra 0,47 y 0,49 en métricas relativas, es decir, reduce el error más de la mitad frente a esa base.

¿De dónde salen los datos y son confiables?

Del PISCOp v3.0, producto oficial del SENAMHI (1981-2025), que combina estaciones y satélites. Es la fuente de referencia para precipitación en el Perú.

¿Qué aporta el prototipo web?

Hace accesible la investigación: cualquiera puede recorrer los datos, las métricas, los resultados, el flujo metodológico y la proyección 2026 desde cualquier dispositivo, sin instalar nada.

Documento de apoyo para la exposición · Tesis: Comparación de algoritmos de regresión de aprendizaje supervisado para la predicción de la precipitación mensual en el Perú · Atahualpa Palomino, Kevin Anthony · Universidad César Vallejo, Sede Lima Este · 2026